Eksplorasi Mandiri Studi Terdahulu: Big data resolving using Apache Spark for load forecasting and demand response in smart grid: A case study of Low Carbon London Project

Disusun Oleh:

Habbi Widagdo (NIM 123140204)

Tautan Repository:

https://github.com/habbiwidagdo/MahaData-Minggu-7.git

A. Ringkasan Jurnal

- Masalah yang diselesaikan:

Penerapan teknologi informasi dan komunikasi seperti meteran pintar (*smart meters*) pada sistem jaringan listrik pintar (*smart grid*) menghasilkan aliran data berukuran masif dan berkecepatan tinggi yang mencakup pembacaan konsumsi energi beserta variabel eksogen seperti data cuaca dan demografi. Masalah spesifik yang dihadapi adalah ketidakmampuan perangkat lunak analisis konvensional dalam mengolah volume data yang sangat besar tersebut, ditambah tingginya beban komputasi dan kompleksitas model *machine learning* konvensional maupun model komposit (*ensemble/neural networks*) yang sulit diinterpretasikan untuk peramalan beban (*load forecasting*) dan evaluasi program respon permintaan (*demand response*) secara efisiem. Sebagai solusi, penelitian ini memanfaatkan ekosistem *big data* Apache Spark (Spark SQL untuk analitik deskriptif dan Spark MLlib untuk analitik prediktif) dengan mengimplementasikan model regresi tunggal yang terukur (*scalable*), mudah diinterpretasikan, dan efisien, seperti *Multivariate Polynomial Regression* (MPR) ter-regularisasi dan *Decision Tree Regression* (DTR) dengan seleksi fitur yang ringkas untuk memprediksi konsumsi beban agregat rumah tangga serta mengevaluasi program tarif *Dynamic Time-of-Use* (DToU). Batasan dari penelitian ini terletak pada tingkat akurasi model yang hanya efektif untuk peramalan beban agregat dan menurun jika diterapkan pada skala rumah tangga individual, ketergantungan kinerja pada kapasitas memori (*RAM*) klaster saat volume data membengkak, serta terbatasnya aksesibilitas data riil mengenai kapasitas jaringan dan produksi energi terbarukan akibat isu privasi dan keamanan data [1].

- Dataset dan Linkungan:
  Artikel asli menggunakan lingkungan komputasi awan di Google Cloud Dataproc dengan klaster yang terdiri dari 1 node *master* (2 vCPU, 7.5 GB RAM) dan 3 node *worker* (masing-masing 2 vCPU, 7.5 GB RAM) untuk menangani pemrosesan *big data.* Detail dataset yang digunakan pada studi ini sebagai berikut:
  - Low Corbon London (LCL) Project:
  - konsumsi energi dari 5.567 rumah tangga di London pada periode November 2011 hingga Februari 2014 dengan interval 30 menit (total lebih dari 167 juta rekaman)
  - Riwaya Data Cuaca London dari Darksky API
  - Data Kategori demografis pelanggan
  - ACORN: Affluent, Comfortable, Adversity
  - Bank holidays
  - Data hari libur bank

- Metode atau Arsitektur:

Arsitektur perangkat lunak yang digunakan dalam penelitian ini adalah modul Spark SQL sebagai analisis deskriptif dalam penelitian ini. Selain itu, modul Spark SQL digunakan untuk menghasilkan statistik ringkasan dari keseluruhan dataset. Matplotlib dan Seaborn digunakan

untuk memvisualisasikan hasil ringkasan yang diperoleh dari Spark SQL. Terakhir Spark MLlib mampu melatih model yang skalabel dan teroptimasi, sehingga pustaka ini digunakan dalam penelitian ini untuk analisis prediktif [1]. Metode eksperimen yang dilakukan pada jurnal ini sebagai berikut.

1. Pengumpulan data dan Integrasi
   Mengumpulkan dan mengintegrasikan data dari riwayat cuaca, hari libur bank, dan *smart meter*.
2. *Pre-processing* Data
   Melakukan penggabungan data (*grouping)*, agregasi data, penanganan *outlier* data, dan pembersihan data kosong (Null/N/A).
3. Analitik Deskriptif
   Menganalisis data dari grafik.
4. Rekayasa Fitur
   Menghapus fitur yang tidak berguna, membuat fitur, dan mengatur fitur target.
5. Analitik Predictive
   Membagi data (latih, uji, dan validasi), mengatur hyperparameter tuning dan pengujian model.

- Hasil Capaian Utama:

Model *Multivariate Polynomial Regression* (MPR) menghasilkan tingkat akurasi yang lebih tinggi dibandingkan *Decision Tree Regression* (DTR)12. Untuk prediksi total konsumsi energi seluruh rumah tangga (5.567 rumah), model MPR (termasuk varian regularisasinya seperti Ridge) mencapai nilai R^2 = 0,963 - 0,965$, sedangkan DTR dengan *max depth = 5* mencapai R^2 = 0,922 [1]. Selain itu Model Ridge Regression direkomendasikan sebagai model terbaik untuk aplikasi *Big Data* karena memiliki waktu pengujian (*testing time*) paling cepat (sekitar 0,015–0,017 detik) serta waktu pelatihan (*fitting time*) yang jauh lebih singkat dibandingkan Lasso dan Elastic Net [1].

- Alasan Pemilihan:

Pemilihan studi ini dikarenakan ketertarikan terhadap implementasi Apache Spark, namun selain itu studi ini memberikan akses publik untuk sumber literatur dan dataset, sehingga mempermudah proses eksplorasi.

B. Tahapan implementasi atau eksperimen

- Tingkat Replikasi:

Menggunakan replikasi parsial dengan mengulang bagian uji coba model Ridge Regression pada subset data blok 0.

- Lingkungan Pengembangan:
    - Google Colab
    - Pyspark
    - Matplotlib
    - Pyspark SQL

- Langkah-langkah:
    - Pre-Processing Data
    - Rekayasa Fitur
    - Pemodelan Machine Learning

- Perbedaan terhadap Artikel Asli:

Eksperimen ini menggunakan tingkat Replikasi Parsial yang dijalankan di *notebook* Google Colab lokal, berbeda dengan artikel asli yang memproses 167 juta baris data menggunakan klaster *cloud* Dataproc. Data dibatasi murni pada subset Block 0 untuk efisiensi RAM. Selain itu, fitur demografi ACORN dihilangkan dari pemodelan karena seluruh rumah tangga di dalam satu blok hunian yang sama sudah tergolong dalam kategori ACORN yang seragam.

C. Hasil pengujian dan analisis

Berdasarkan hasil pengujian model Ridge Regression didapatkan hasil evaluasi sebagai berikut.

Tabel 1. Hasil Evaluasi

R^2	RMSE	MAE
0.7895	9.6417	7.5922

Pada eksperimen replikasi ini, model Ridge Regression mencetak metrik R^2 sebesar 0.7895 dan RMSE sebesar 9.6417. Evaluasi ini menunjukkan selisih kinerja dan penurunan akurasi yang cukup signifikan jika dibandingkan dengan temuan Ali et al. (2024), di mana model mereka untuk subset Block 0 mencapai $R^2 = 0.943$ dan RMSE = 2.490.

D. Kendala dan refleksi

Kendala:

Proses inisialisasi awal (*data loading*) membutuhkan waktu komputasi yang sangat lambat dikarenakan proses eksperimen dicoba dijalankan di lokal dengan menggunakan data project besar bukan block. Selain itu, proses agregasi data memicu peringatan *NumberFormatException* karena tipe data tidak sejalan. Masih banyak pemahaman yang belum memadai terkait teknis penggunaan Apache Spark dari Pyspark, sehingga memperlambat proses eksperimen.

Refleksi:

Pemuatan data dipercepat dengan menggunakan Google Colab berbasis cloud sebagai lingkungan pengembangan. Perlunya mempelajari basic Pyspark untuk mempermudah proses pemahaman sintaksis kode.

E. Tautan Kode

Hasil dan *sourcecode* dapat diakses melalui tautan berikut:

- https://github.com/habbiwidagdo/MahaData-Minggu-7.git
- https://colab.research.google.com/drive/1E9F6lUKxiE3ycU6mqPRzzOGMZQqjsW8X?usp=sharing

Daftar Pustaka

[1] H. A. E. S. Ali, M. H. Alham, and D. K. Ibrahim, “Big data resolving using Apache Spark for load forecasting and demand response in smart grid: a case study of Low Carbon London Project,” *J. Big Data*, vol. 11, 2024, doi: 10.1186/s40537-024-00909-6.